Прохождение лаб: Best practices

Папка в s3

Hadoop-streaming прекрасно работает с s3 в качестве источника данных -input.

```
hadoop jar ~/stream.jar -file mapper.py -mapper mapper.py -input s3n://datalabs.npl/facetz_2015_02_20/ -output /results
```

Не стоит копировать папку себе в домашнюю директорию. Она весит больше 40 Гб. Вас 25 человек. Если каждый так будет делать, то вместе вы займете 1 Тб. И это только по одной лабе.

2. Семплинг

а) Не стоит тестировать свой MR-job на всей папке в s3. Лучше вначале сделать каким-то образом семпл из одного из файлов.

```
hdfs dfs -tail s3n://datalabs.npl/facetz_2015_02_20/part-00000 > sample.txt
```

б) После этого посмотреть отрабатывает ли mapper и reducer локально. Пример:

```
cat sample.txt | python mapper.py > map_results.txt
sort map_results > shuffled.txt
cat shuffled.txt | python reducer.py > mr_results.txt
```

- в) После этого можно скопировать себе один из файлов (например, part-0000) и прогнать это все на нем.
- г) Если все ок, то можно попробовать теперь написать MR-job, но опять же не на всей папке. а подать на вход только один из файлов.

```
hadoop jar ~/stream.jar -file mapper.py -file reducer.py -mapper mapper.py -reducer reducer.py -input s3n://datalabs.npl/facetz_2015_02_20/part-00000 -output /results
```

д) Если MR-job отработал нормально, то можно запустить и на всей папке.

3. Отладка мапперов и редюсеров

В Python существует конструкция try-except, которая помогает выявлять ошибки. Пример:

```
for line in sys.stdin:
try:
u1, u2, country, u3, payment = line.strip().split(',')
print '\t'.join([country.strip(), payment.strip()])
except Exception, e:
print str(e)
```

Главный вывод: запускать MR-job на полных данных только тогда, когда на 90% уверены, что все верно написано.

4. Логи MR-jobs

Hadoop имеет удобную WEB-консоль для поиска по логам MR-joboв.

Когда вы запускаете MR-job, в терминале вы как правило видите вывод только "верхушки" стектрейса java-приложения, отвечающего за запуск MR-joba, из которого бывает неочевидно из-за чего конкретно произошла ошибка:

```
16/03/20 21:03:25 INFO mapreduce.Job: Task Id : attempt_ids598061603_0066_m_000000_2. Setus : FAILED
ETTOT: java.lang.RuntlmeException: PipeMapRed.waitOutputThreads() subprocess failed with code 1
at org.spatch.hudop.streaming.PipeMapRed.waitOutputThreads() subprocess failed with code 1
at org.spatch.hudop.streaming.PipeMapRed.pintsed.dips6405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405198405184051984
```

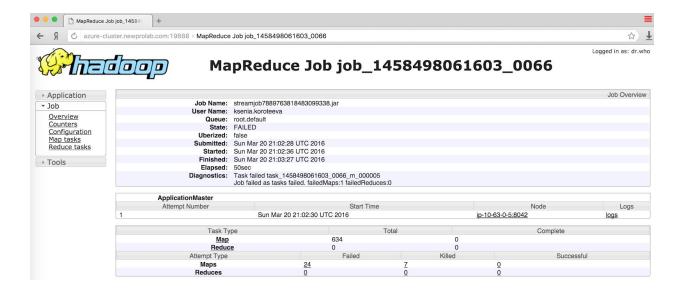
Чтобы докопаться до сути, необходимо найти лог вашего joba в JobHistory. Для этого необходимо зайти по адресу:

http://azure-cluster.newprolab.com:19888/jobhistory

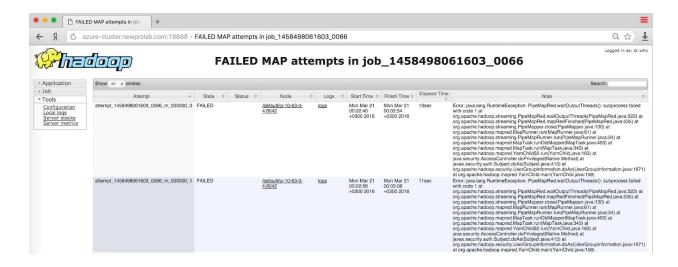


Последний job будет в списке сверху. Можно воспользоваться поиском, для этого необходимо скопировать номер joba (job_XXXXXXXXXXXXXXXXXX) из терминала и вставить его в поле "Search" в JobHistory.

Далее нажать на ссылку в колонке "Job ID":



Внизу экрана будет отображаться статистика по этому job в разрезе Maps и Reduces. При нажатии на ссылку под соответствующим числом, например, число в строке "Maps" и колонке "Failed" отображается список, в данном случае маперов завершенных неуспешно:



По ссылке в колонке "Logs" доступен полный лог мапера:



из которого уже видно из-за чего произошла ошибка.